



Sistema de clasificación automática de mamografías según la densidad del tejido mamario para la unidad de radiología de la Fundación Valle del Lili

Proyecto de Grado

Andrés Camilo Romero Ruiz

Brayan Steven Ortega García

Juan Camilo Salazar Quintero

Tutores

Ángela Villota Gómez, PhD

Andrés Aristizábal Pinzón, PhD

Aníbal Sosa Aguirre, PhD

Asesor Técnico

Juan Felipe Orejuela

Facultad Barberi de Ingeniería, Diseño y Ciencias Aplicadas

Ingeniería de Sistemas

Santiago De Cali

2025

TABLA DE CONTENIDO

Resumen	3
Abstract	4
Índice de figuras	5
Índice de tablas	6
1. INTRODUCCIÓN	7
1.1. Contexto	7
1.2. Planteamiento del problema	8
1.3. Impacto del proyecto	8
1.4. Objetivo General	9
1.5. Objetivos Específicos	9
1.6. Organización del Documento	9
2. ANTECEDENTES	11
2.1. Marco Teórico	11
2.2. Estado del arte	14
3. METODOLOGÍA	21
3.1. Comprensión del negocio	22
3.2. Comprensión de los datos	22
3.3. Preparación de los datos	22
3.4. Modelado	22
3.5. Evaluación	23
3.6. Desarrollo Web	23
4. PRESENTACIÓN DE LA PROPUESTA	25
4.1. Comprensión del negocio	25
4.2. Comprensión de los datos	26
4.3. Preparación de los datos	29
4.4. Modelado	34
4.5. Evaluación	38
4.6. Desarrollo web	49
6. CONCLUSIONES Y FUTURO TRABAJO.	55
7. ANEXOS	57
7.1. Glosario de términos	57
7.2. Lista de acrónimos	59
8. REFERENCIAS BIBLIOGRÁFICAS	61

Resumen

La densidad mamaria es una característica anatómica crucial que se determina a partir de estudios de mamografía. Esta medida es de gran importancia clínica, ya que un tejido mamario denso dificulta la visualización y detección de posibles tumores o anomalías. Además, una alta densidad mamaria se asocia con un mayor riesgo de desarrollar cáncer de mama. Por estas razones, las personas con densidad mamaria alta suelen requerir la remisión a estudios complementarios para obtener un diagnóstico más exhaustivo y preciso.

El problema central encontrado está en el alto volumen de mamografías y el tiempo limitado para clasificar y decidir sobre las remisiones a estudios complementarios. Esta presión, sumada a la variabilidad en la interpretación por parte de los radiólogos, evidencia la necesidad de implementar sistemas basados en inteligencia artificial que agilicen y estandaricen la clasificación de la densidad mamaria, permitiendo diagnósticos precisos y oportunos.

Algunas propuestas previas han empleado modelos de machine learning y técnicas de procesamiento de imágenes para clasificar automáticamente la densidad mamaria según el sistema estandarizado BI-RADS (Breast Imaging-Reporting and Data System), que define cuatro categorías: A (predominantemente grasa), B (dispersa), C (heterogéneamente densa) y D (extremadamente densa) (Spak et al., 2017). Sin embargo, persisten desafíos como el bajo desempeño en escenarios multiclase, la dependencia del formato y la calidad de las imágenes, y las altas demandas computacionales.

En este contexto se desarrolló y validó una solución basada en inteligencia artificial siguiendo la metodología CRISP-DM, entrenando modelos para la clasificación binaria (AdaBoost) y multiclase (XGBoost) del parénquima mamario según BI-RADS, ambos integrados en un *pipeline* automatizado y en una interfaz web funcional que permite visualizar el proceso completo. Los resultados obtenidos incluyen un *F1-score* del 87% para la clasificación binaria y del 71% para la clasificación multiclase, junto con tiempos de respuesta promedio de 0.13 segundos y 0.0017 segundos, respectivamente, aportando así una herramienta reproducible para el apoyo diagnóstico en la Fundación Valle del Lili.

Palabras clave: mamografía, densidad mamaria, inteligencia artificial, clasificación BI-RADS, *machine learning*, *pipeline*.

Abstract

Breast density classification presents challenges related to interobserver variability and limited evaluation time in mammography interpretation. To address these constraints at Fundación Valle del Lili, an AI system was developed using machine learning algorithms trained on radiomic features from DICOM mammograms. Binary (AdaBoost) and multiclass (XGBoost) BI-RADS classification models were validated on institutional and external datasets, achieving F1-scores of 87% and 71% with inference times of 0.13s and 0.002s respectively. The results demonstrate that classic machine learning on tabular radiomic data provides interpretable and efficient support tools for breast density assessment.

Key words: breast density, artificial intelligence, BI-RADS classification, machine learning, radiomic features.

Índice de figuras

Ilustración 1. Estructura del proyecto y organización de directorios	21
Ilustración 2. Diagrama de la metodología	24
Ilustración 3. Diagrama de distribución de densidades en conjunto de imágenes de la FVL	27
Ilustración 4. Diagrama de distribución de densidades en archivo CSV	28
Ilustración 5. Diagrama de distribución de densidades en conjunto de imágenes de la RSNA	29
Ilustración 6. Matriz de confusión del modelo A/B con XGBoost	40
Ilustración 7. Matriz de confusión del modelo C/D con XGBoost	41
Ilustración 8. Matriz de confusión del modelo XGBoost multiclase	43
Ilustración 9. Ranking de las 10 características radiómicas con mayor peso positivo según Log-Odds	48
Ilustración 10. Ranking de las 10 características radiómicas con mayor peso negativo según Log-Odds	49
Ilustración 11. Diagrama de infraestructura y flujo de trabajo del Pipeline automatizado.	51

Índice de tablas

Tabla 1. Matriz de incidencias	19
Tabla 2. Variables seleccionadas por VIF para los modelos binario y multiclase	31
Tabla 3. Hiper Parámetros óptimos para Regresión Logística	35
Tabla 4. Hiper Parámetros óptimos para SVM	35
Tabla 5. Hiper Parámetros óptimos para AdaBoost	36
Tabla 6. Hiper Parámetros óptimos para XGBoost	36
Tabla 7. Hiper Parámetros óptimos para PyTorch Tabular	37
Tabla 8. Métricas de los modelos no denso/denso	39
Tabla 9. Métricas de los modelos A/B	39
Tabla 10. Métricas de los modelos C/D	40
Tabla 11. Métricas de los modelos multiclase	42
Tabla 12. Métricas de los modelos evaluados con mamografías de la FVL	44
Tabla 13. Métricas de AdaBoost y XGBoost con mamografías de la RSNA	46
Tabla 14. Pruebas Realizadas	52

1. INTRODUCCIÓN

1.1. Contexto

La clasificación de la densidad del tejido mamario es un componente fundamental en la interpretación de mamografías, realizada de acuerdo al sistema estandarizado BI-RADS que organiza esta densidad en cuatro categorías: A (predominantemente grasa), B (dispersa), C (heterogéneamente densa) y D (extremadamente densa) (Spak et al., 2017). Esta clasificación permite determinar la necesidad de estudios complementarios como ultrasonidos o resonancias magnéticas para pacientes con tejido denso (categorías C y D), quienes presentan mayor riesgo de desarrollar cáncer de mama y en quienes los tumores son más difíciles de detectar debido a que la alta densidad puede ocultarlos en la imagen.

Actualmente, los radiólogos deben evaluar visualmente la composición del tejido mamario y asignar manualmente una categoría de densidad, proceso que, aunque estandarizado, introduce variabilidad interobservador y consume tiempo valioso que podría dedicarse a la identificación de hallazgos patológicos críticos.

La Fundación Valle del Lili (FVL) es un importante Hospital Universitario ubicado en la ciudad de Cali, Colombia, dedicado a la formación del talento humano en salud y a la atención de alta complejidad de pacientes (Fundación Valle del Lili, s.f.). Dentro de sus servicios diagnósticos, el área de imagenología mamaria enfrenta precisamente este desafío operativo relacionado con la clasificación de la densidad del tejido mamario. De los 22 radiólogos de la institución, 18 trabajan a tiempo completo, y de estos, solo una porción está especializada en imagenología mamaria. Este recurso limitado resulta en ventanas de tiempo reducidas para que cada radiólogo evalúe todos los aspectos de cada mamografía.

La ausencia de herramientas automatizadas para apoyar esta clasificación representa una oportunidad de mejora en la eficiencia del servicio radiológico y en la consistencia diagnóstica de la FVL. Un sistema automatizado de clasificación de densidad mamaria funcionaría como herramienta de apoyo diagnóstico y segunda opinión, ayudando a reducir la variabilidad interobservador y proporcionando una evaluación objetiva basada en valores cuantitativos. Esta herramienta permitiría a los radiólogos validar sus evaluaciones visuales y concentrar su experticia en la detección e interpretación de hallazgos críticos, mejorando así la calidad y consistencia general del servicio de imagenología mamaria.

1.2. Planteamiento del problema

La clasificación de densidad mamaria es una tarea crítica en radiología que presenta desafíos operacionales y técnicos significativos. Los radiólogos deben evaluar múltiples estudios con tiempo limitado por paciente, lo que genera variabilidad en la interpretación de la densidad mamaria. Esta inconsistencia impacta la calidad de los reportes y puede retrasar decisiones clínicas sobre estudios complementarios.

En centros médicos como la Fundación Valle del Lili, la ausencia de sistemas automatizados para clasificar de manera reproducible y consistente la densidad mamaria limita la estandarización diagnóstica para garantizar que el criterio BI-RADS se aplique de forma uniforme entre observadores. Desde la perspectiva técnica, esta problemática se agrava por desafíos adicionales como el desbalance de clases (subrepresentación de categorías A y D) y la variabilidad introducida por diferentes equipos de mamografía y protocolos de adquisición. Ante esta necesidad, se evidencia la oportunidad de desarrollar soluciones basadas en características radiómicas cuantitativas e inteligencia artificial que automaticen la clasificación de densidad mamaria, reduzcan la variabilidad interobservador y mejoren la consistencia del flujo de trabajo radiológico.

1.3. Impacto del proyecto

A través del proyecto se busca desarrollar una solución de apoyo diagnóstico y segunda opinión para los radiólogos de la FVL. El sistema proporcionará evaluaciones objetivas y estandarizadas basadas en características radiómicas cuantitativas, reduciendo la variabilidad interobservador inherente a la evaluación visual subjetiva, especialmente en casos limítrofes entre categorías.

Desde la perspectiva clínica, contar con una clasificación automática permitiría a los radiólogos validar sus evaluaciones de forma más eficiente, facilitando decisiones informadas sobre la necesidad de estudios complementarios en pacientes con tejido denso (categorías C y D) y contribuyendo a una comunicación más clara y oportuna sobre el estado mamario de cada paciente.

1.4. Objetivo General

Desarrollar y validar modelos basados en inteligencia artificial para la clasificación automática de la densidad del parénquima (tejido fibroglandular) mamario en mamografías de pacientes de la Fundación Valle del Lili.

1.5. Objetivos Específicos

OE 1. Preparar las mamografías en formato DICOM provenientes de la FVL mediante la segmentación del área de interés y extracción de características radiómicas para su posterior procesamiento.

OE 2. Procesar las características radiómicas obtenidas de la FVL aplicando normalización, selección de características y transformación de datos para el entrenamiento de los modelos de aprendizaje automático.

OE 3. Diseñar y entrenar modelos de aprendizaje automático para la clasificación del parénquima mamario según el sistema BI-RADS, abarcando tanto modelos multiclase (A, B, C y D) como modelos binarios (no denso / denso).

OE 4. Evaluar los modelos entrenados mediante las métricas de desempeño de *Accuracy*, *Precision*, *Recall*, *F1-score*.

OE 5. Desarrollar una aplicación web y un flujo de datos que permitan visualizar el proceso desde que una mamografía ingresa al sistema hasta que se obtiene la predicción del modelo.

1.6. Organización del Documento

El documento se organiza de la siguiente manera: el **capítulo 2 (Antecedentes)** presenta el contexto teórico y clínico del problema, incluyendo conceptos de mamografía, densidad mamaria, BI-RADS, procesamiento de imágenes, modelos de *Machine Learning* y el estado del arte. El **capítulo 3 (Metodología)** describe el enfoque seguido (CRISP-DM), desde la comprensión del negocio y los datos hasta la evaluación de los modelos y el desarrollo de una aplicación web. El **capítulo 4 (Presentación de la propuesta)** detalla la solución técnica desarrollada, abarcando el análisis y tratamiento de datos, los modelos de clasificación binarios y multiclase, y la integración de los componentes web. El **capítulo 5**

(Validación y resultados obtenidos) expone el desempeño de los modelos, compara métricas y justifica la selección final de los modelos. El **capítulo 6 (Conclusiones y trabajo futuro)** sintetiza los hallazgos, discute el impacto del sistema, identifica limitaciones y plantea líneas de mejora e integración futura.

2. ANTECEDENTES

2.1. Marco Teórico

Este marco teórico establecerá qué es una mamografía, el formato DICOM en que se almacena, su importancia en el diagnóstico del cáncer de mama y por qué la detección de la densidad mamaria es clave como factor de riesgo. Luego se explicarán los conceptos técnicos fundamentales: segmentación de imágenes, características radiómicas, y modelos de clasificación supervisada con sus métricas de evaluación. Finalmente, se mostrará cómo se integran estos componentes mediante pipelines de procesamiento automatizado que transforman imágenes médicas en predicciones clínicas.

2.1.1. Mamografía y su importancia en el diagnóstico del cáncer de mama

Una mamografía es una radiografía de la mama utilizada como estudio estandarizado de radiología para detectar la presencia del cáncer de mama antes de que se extienda, cuya interpretación depende en gran medida de la experticia y conocimiento del radiólogo (NIH, s.f.). Durante esta interpretación, el radiólogo no solo busca lesiones sospechosas, sino que también evalúa la composición del tejido mamario, determinando su densidad según la proporción de tejido glandular y fibroso respecto al tejido graso.

Para estandarizar esta evaluación de densidad y reducir la variabilidad entre observadores, el Colegio Americano de Radiólogos desarrolló el sistema BI-RADS (Breast Imaging-Reporting and Data System), que organiza las mamografías en cuatro categorías según la densidad del parénquima mamario: A (principalmente tejido graso), B (algunas zonas de tejido fibroso y glandular denso), C (mezcla casi igual de tejido graso y denso), y D (principalmente tejido denso).

2.1.2. Densidad mamaria como factor de riesgo

La clasificación de la densidad es crucial para determinar la necesidad de estudios complementarios, como ultrasonidos o resonancias magnéticas, especialmente en mujeres con tejido mamario denso pertenecientes a las categorías C y D. El tejido mamario denso dificulta la detección del cáncer de mama, ya que se visualiza de color blanco en una mamografía, al igual que los tumores, reduciendo la precisión diagnóstica (Sociedad Canadiense del Cáncer, 2024).

Más aún, se ha demostrado que el riesgo de cáncer de mama aumenta con la densidad mamaria, específicamente, las densidades mamarias iguales o superiores al 75% presentan un riesgo hasta 4.7 veces

mayor de desarrollar cáncer de mama (Boyd et al., 2007). Esta problemática de menor detectabilidad y mayor riesgo intrínseco justifica la necesidad de un sistema automatizado capaz de clasificar la densidad mamaria de forma consistente y objetiva.

2.1.3. Estándar DICOM para almacenamiento de imágenes médicas

Las mamografías digitales se almacenan y transmiten utilizando el estándar internacional DICOM (*Digital Imaging and Communications in Medicine*). Este garantiza la interoperabilidad universal entre plataformas de software y dispositivos de imágenes clínicas, incluyendo el uso de encabezados o etiquetas con información relevante del estudio, paciente, modalidad y procedimiento, facilitando la integración entre sistemas encargados de gestionar y distribuir estudios radiológicos.

2.1.4. Segmentación de imágenes

Antes de extraer características cuantitativas de las mamografías, se requiere la segmentación de imágenes, que consiste en dividir una imagen en regiones o segmentos con el fin de identificar zonas de interés. Al descomponer una mamografía en segmentos se obtiene un tratamiento más eficiente y rápido, permitiendo descartar el fondo oscuro y enfocarse en la región mamaria específica para ofrecer un análisis centrado en el tejido relevante.

2.1.5. Características radiómicas

Las características radiómicas son valores cuantitativos resultantes de procesar imágenes médicas a través de algoritmos automatizados, con el objetivo de asociarlas a estados fisiológicos concretos para mejorar la precisión diagnóstica, pronóstica y predictiva. Estos descriptores capturan propiedades del tejido como textura, heterogeneidad, intensidad y forma, transformando información visual en datos estructurados analizables para la solución de problemas clínicos.

2.1.6. Modelo

Un modelo en el área del *Machine Learning* es una estructura matemática capaz de identificar características y patrones presentes en datos como imágenes, valores numéricos o entradas de texto, con el fin de realizar tareas de clasificación o regresión para las que no fue programado de manera explícita. En el contexto de clasificación de densidad mamaria, un modelo se encarga de identificar relaciones

potenciales entre las características radiómicas de entrada y la categoría BI-RADS correspondiente como variable de salida.

Para construir estos modelos se recurre al aprendizaje supervisado, un paradigma en el que un algoritmo aprende a partir de ejemplos de entrada emparejados con sus etiquetas correctas, de modo que pueda predecir la categoría apropiada en datos nuevos (Mitchell, 1997). Para el abordaje del problema se aplicaron diversos algoritmos, entre ellos: la **regresión logística**, que estima las probabilidades de cada clase mediante funciones matemáticas y destaca por su interpretabilidad; las máquinas de vectores de soporte (**SVM**), que buscan el hiperplano que maximiza el margen de separación entre clases; los métodos de conjunto como **AdaBoost** y **XGBoost**, que combinan múltiples clasificadores débiles para mejorar la precisión general; y las **redes neuronales** profundas, que pueden aprender representaciones complejas directamente de los datos, aunque requieren mayores volúmenes de información y recursos computacionales.

2.1.7. Selección de características y reducción de dimensionalidad

Dado que las características radiómicas pueden alcanzar cientos de descriptores, es crucial identificar aquellas más relevantes para la tarea de clasificación. La información mutua es una medida que cuantifica la dependencia estadística entre dos variables, permitiendo identificar las características más informativas respecto a la variable objetivo. Esta técnica es especialmente útil cuando existe un alto número de características o se sospecha que algunas son redundantes entre sí, situación común en el análisis radiómico donde múltiples descriptores pueden capturar propiedades similares del tejido.

Complementariamente, el análisis de *Log-Odds* (que representan el logaritmo natural del *odds ratio*) permite interpretar cómo cada característica radiómica contribuye a la probabilidad de que una mamografía pertenezca a una categoría específica de densidad. Este concepto estadístico, fundamental en análisis categórico, permite cuantificar y visualizar el efecto direccional de cada variable en la clasificación, proporcionando una capa adicional de interpretabilidad clínica al modelo.

2.1.8. Evaluación de modelos mediante métricas de desempeño

Las métricas de desempeño se utilizan para cuantificar el progreso y la calidad de un modelo de aprendizaje automático, calculadas a partir de la matriz de confusión que distingue entre verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos. Según el propósito del modelo se da prioridad a unas medidas sobre otras como principales indicadores de progreso.

La exactitud (*Accuracy*) mide la proporción de predicciones correctas sobre el total de casos. La precisión (*Precision*) evalúa qué proporción de las predicciones positivas fueron correctas, reduciendo falsas alarmas. La sensibilidad o *Recall* determina la capacidad del modelo para detectar todas las instancias de cada clase correctamente, aspecto crucial en aplicaciones médicas donde omitir casos puede tener consecuencias en la práctica clínica. El *F1-score* proporciona un balance armónico entre precisión y sensibilidad, siendo especialmente útil cuando ambas métricas son igualmente importantes y existe desbalance entre clases, situación común en clasificación de densidad mamaria donde las categorías extremas (A y D) suelen estar subrepresentadas respecto a las intermedias (B y C).

2.1.9. Pipeline de procesamiento y automatización

Un pipeline en términos informáticos se define como un conjunto de pasos cuyos resultados o productos son insumos del siguiente hasta su finalización, con el fin de automatizar procesos, reducir tiempos de entrega y aumentar la calidad entre etapas. En el contexto de clasificación de densidad mamaria, el pipeline integra todas las etapas previamente descritas: validación de archivos DICOM, preprocesamiento mediante segmentación, extracción de características radiómicas, selección de variables, entrenamiento y validación del modelo, y despliegue de los artefactos resultantes para su uso clínico. Esta automatización garantiza reproducibilidad, escalabilidad y consistencia en el procesamiento de nuevas mamografías.

2.2. Estado del arte

Dada la alta relevancia de la clasificación de la densidad mamaria en el ámbito médico, una diversidad de metodologías y herramientas han sido propuestas y exploradas para abordar esta problemática. Para distinguir estas soluciones entre sí, se definieron cinco criterios de comparación:

- **Conjunto de datos:** procedencia de los datos utilizados, incluyendo formato y tamaño muestral.
- **Aspectos metodológicos:**

Clasificación: enfoque para la categorización, ya sea binaria (no denso/denso) o multiclase (4 categorías BI-RADS).

Modelos: algoritmos y arquitecturas de aprendizaje automático empleadas.

Extracción de características: técnicas para obtener atributos relevantes de las mamografías si aplica.

- **Resultados:** métricas del mejor modelo.

Con el objetivo de establecer el estado del arte para el presente proyecto, se describirán cuatro publicaciones que abordan la clasificación de la densidad mamaria. Estas fueron seleccionadas teniendo en cuenta los siguientes motivos:

- **Vinculación temática:** los estudios abordan el problema de clasificación de densidad mamaria mediante *Machine Learning*. Destacando un proyecto desarrollado en la UAO (Universidad Autónoma de Occidente) que utilizó datos de la FVL, compartiendo tanto el contexto clínico como el entorno tecnológico del proyecto actual.
- **Diversidad metodológica:** se procuró incluir una variedad de enfoques y técnicas, desde modelos clásicos de aprendizaje, hasta arquitecturas profundas más recientes.
- **Relevancia:** estudios de instituciones reconocidas y que han recibido múltiples citas académicas.

A continuación, se describen las cuatro publicaciones, en cada una se detallan los criterios de comparación:

Publicación 1. Sistema de clasificación de tipo de tejido mamario con Machine Learning

- **Autores:** Arturo Angulo et al.
- **Institución:** Universidad Autónoma de Occidente (UAO) en colaboración con la Fundación Valle del Lili (FVL)
- **Año:** 2020

Tipo de clasificación:

Binaria (tejido denso vs. no denso) y clasificación entre grupos de categorías BI-RADS (A/B y C/D).

Conjunto de datos:

El estudio utilizó 2372 mamografías en formato DICOM provenientes de 1207 pacientes de la FVL.

Aspectos metodológicos:

Se implementó un pipeline completo que incluyó preprocesamiento de imágenes y extracción de 290 características radiómicas mediante la librería PyRadiomics. Se evaluaron cinco modelos de clasificación: Máquinas de Vectores de Soporte (SVM), *Random Forest*, *k-Nearest Neighbors* (KNN), AdaBoost y

Regresión Logística. Se empleó la librería Imbalanced-learn para el balanceo de datos, *PowerTransformer* para el escalado y *GridSearchCV* para la optimización de hiperparámetros.

Resultados:

Para la clasificación binaria (tejido denso y no denso), el modelo SVM obtuvo un *Accuracy* del 85.8%. En la clasificación entre grupos de categorías BI-RADS, SVM alcanzó un *Accuracy* del 88% para A-B y del 87% para C-D. Este estudio destaca la importancia del balanceo de datos, la selección de características y el uso de escaladores para mejorar el rendimiento de los modelos.

Publicación 2. Computer aided diagnosis system for breast density classification in mammograms

- **Autores:** Shrinithi et al.
- **Institución:** *Department of Electronics and Communication Engineering, Amrita School of Engineering, Coimbatore, Amrita Vishwa Vidyapeetham, India*
- **Año:** 2020

Tipo de clasificación:

Multiclase (cuatro categorías BI-RADS) y binaria (denso vs. no denso).

Conjunto de datos:

Se utilizaron 624 mamografías en formato PNG de 197 pacientes del dataset público DDSM (*Digital Database for Screening Mammography*).

Aspectos metodológicos:

Se evaluaron diversos descriptores de características locales: SURF (*Speeded Up Robust Features*), LBP (*Local Binary Patterns*) y GLCM (*Gray-Level Co-occurrence Matrix*). Para la selección de características se empleó ANOVA (*Analysis of Variance*). Los modelos de clasificación evaluados fueron SVM, Random Forest, KNN y Árboles de Decisión.

Resultados:

Para la clasificación multiclase, SVM logró un *Accuracy* del 73%. En la clasificación binaria, el modelo alcanzó un *Accuracy* del 90%. Una limitación importante es el uso del formato PNG, que no preserva los metadatos clínicos presentes en imágenes DICOM.

Publicación 3. Classification of breast density categories based on SE-Attention neural networks

- **Autores:** Deng et al.
- **Institución:** *College of Information and Computer y College of Data Science, Taiyuan University of Technology; Department of Radiology, First Hospital of Shanxi Medical University, China*
- **Año:** 2020

Tipo de clasificación:

Multiclase (cuatro categorías BI-RADS).

Conjunto de datos:

Se utilizaron 18,157 mamografías de 4,982 pacientes del *First Hospital of Shanxi Medical University*.

Aspectos metodológicos:

El preprocesamiento incluyó eliminación del fondo y del músculo pectoral, seguido de aumento de datos mediante transformación de escala de grises, recorte aleatorio, rotación y blanqueamiento para abordar el desequilibrio del conjunto de datos. Se utilizaron tres arquitecturas de CNN: *Inception-V4*, *ResNeXt* y *DenseNet*, integrando el mecanismo *SE-Attention* en las últimas tres etapas. La estrategia de entrenamiento empleó validación cruzada de 10 pliegues.

Resultados:

El mejor modelo fue *Inception-V4* con *SE-Attention*, alcanzando un *Accuracy* general del 92.17%. Por categoría, obtuvo una *Precision* del 90.16% para A, 91.81% para B, 94.11% para C y 89.68% para D. Estos resultados sugieren que la integración del mecanismo *SE-Attention* es efectiva para extraer características más robustas y mejorar la capacidad de generalización.

Publicación 4. Deep learning prediction of mammographic breast density using screening data

- **Autores:** Wang et al.
- **Institución:** *Taizhou Cancer Hospital, Taizhou, China*
- **Año:** 2025

Tipo de clasificación:

Multiclase (cuatro categorías BI-RADS).

Conjunto de datos:

El estudio utilizó 57,282 mamografías de screening de 9,621 mujeres del Taizhou Cancer Hospital.

Aspectos metodológicos:

Se evaluaron cuatro arquitecturas de *Deep Learning*: *ResNet50*, *InceptionV3*, *DenseNet121* y *Xception*. Estas redes convolucionales son conocidas por su capacidad para aprender representaciones jerárquicas y abstractas de las imágenes, haciéndolas adecuadas para tareas de clasificación médica.

Resultados:

InceptionV3 demostró el mejor rendimiento, con una *Precision* del 89.5% para la categoría A, 85.7% para B, 95.3% para C y 95.2% para D.

Matriz de incidencias

A continuación, se presenta una tabla comparativa que resume los aspectos clave de los proyectos revisados.

Tabla 1. Matriz de incidencias

Publicación	Conjunto de datos	Modelos probados	Tipo de Clasificación	Extracción de características	Mejor modelo	Métricas del mejor modelo
Sistema de clasificación de tipo de tejido mamario con machine learning (Arturo Angulo et al., 2020)	2,372 mamografías de la Fundación Valle del Lili	SVM, Random Forest, KNN, AdaBoost, Regresión Logística	Binaria	Radiómicas	SVM	<i>Accuracy</i> del 85.8%
Classification of breast density categories based on SE-Attention neural networks (Deng et al., 2020)	18,157 mamografías del <i>First Hospital of Shanxi Medical University</i>	Inception-V4, ResNeXt, DenseNet	Multiclase	N/A	Inception V4	<i>Precision</i> del 89.07% en A, 92.26% en B, 93.39% en C, 86.59% en D.
Computer aided diagnosis system for breast density classification in mammograms (Shrinithi et al., 2022)	624 mamografías del conjunto DDSM	SVM, Random Forest, KNN, Árbol de Decisión	Multiclase y Binaria	Descriptores locales	SVM	<i>Accuracy</i> multiclase del 73% <i>Accuracy</i> binaria del 90%
Deep learning prediction of mammographic breast density using screening data (Wang et al., 2025)	57,282 mamografías del <i>Taizhou Cancer Hospital</i>	ResNet50, InceptionV3, DenseNet121, Xception	Multiclase	N/A	InceptionV3	<i>Precision</i> del 89.5% en A, 85.7% en B, 95.3% en C, 95.2% en D.

La matriz de incidencias muestra que los estudios con *Deep Learning* (*Inception-V4*, *ResNeXt*, *DenseNet*, *InceptionV3*, *Xception*) que trabajan directamente con imágenes completas logran resultados superiores al 90% en clasificación multiclase. Por otro lado, los enfoques de *Machine Learning* clásico obtienen buen desempeño en clasificación binaria (90% de *Accuracy* con SVM), pero su rendimiento es menor en clasificación multiclase (73% de *Accuracy* con SVM). Sin embargo, esta diferencia no indica que un enfoque sea mejor que otro, sino que cada uno es más adecuado según el tipo de datos disponibles. Las arquitecturas de *Deep Learning* están diseñadas para aprender directamente desde imágenes, lo que requiere grandes volúmenes de datos (entre 18,157 y 57,282 mamografías en los estudios revisados) y recursos computacionales considerables.

En este proyecto la situación es diferente porque se cuenta con características radiómicas previamente extraídas mediante PyRadiomics, es decir, datos tabulares estructurados que describen cuantitativamente las propiedades del tejido. Para este tipo de datos, los algoritmos de *Machine Learning* clásico (SVM, Regresión Logística, *Random Forest*, AdaBoost, XGBoost) son la opción más apropiada. Estos modelos están diseñados específicamente para trabajar con características estructuradas, requieren menos recursos computacionales, permiten mayor interpretabilidad clínica al identificar qué características radiómicas son más relevantes, y pueden alcanzar resultados competitivos cuando se cuenta con características bien seleccionadas.

El proyecto de Angulo et al. (2020) en la UAO, que utilizó datos DICOM de la misma Fundación Valle del Lili con características radiómicas extraídas mediante PyRadiomics y algoritmos de *Machine Learning* tradicional, representa la referencia más directamente aplicable al presente trabajo. La elección de *Machine Learning* clásico se ajusta a la naturaleza de los datos disponibles y permite aprovechar de manera óptima la información radiómica ya extraída.

3. METODOLOGÍA

Para el desarrollo del proyecto se adaptó la metodología **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) (Chapman et al., 2000). La adaptación consistió en modificar la última etapa correspondiente al despliegue, al encontrarse fuera del alcance del proyecto, e incorporar la etapa de desarrollo web con el objetivo de entregar un producto que permita visualizar el pipeline de clasificación automática. Este enfoque iterativo y flexible asegura una gestión estructurada para cumplir con los objetivos específicos del proyecto.

El proyecto se implementó siguiendo una arquitectura modular que organiza el código en componentes diferenciados, facilitando así la reproducibilidad y mantenimiento a lo largo de todas las fases. La Ilustración 1 presenta la estructura del repositorio utilizada durante el desarrollo.



Ilustración 1. Estructura del proyecto y organización de directorios

Esta organización permitió una implementación ordenada de cada fase de CRISP-DM que se puede visualizar en la Ilustración 2 y cuyos detalles se describen a continuación.

3.1. Comprensión del negocio

Se inició el proyecto mediante la identificación y análisis del contexto clínico en la FVL, definiendo los objetivos y el alcance desde la perspectiva institucional. Para ello, se realizaron reuniones junto al asesor técnico y el equipo de FVL, lo que permitió comprender y resolver dudas. Además, se llevó a cabo un proceso de investigación con el objetivo de familiarizarnos con los términos y conceptos médicos para el desarrollo del proyecto. Como resultado de este proceso, se recopilaron las expectativas y requisitos del equipo médico y se evaluaron los criterios de éxito, todos ellos según los objetivos específicos OE1 y OE2.

3.2. Comprensión de los datos

En esta fase se realizó una inmersión continua e incremental sobre los datos proporcionados por la FVL, abarcando mamografías en formato DICOM y archivos complementarios en CSV. El trabajo incluyó la recopilación inicial de los datos, verificación de su integridad y exploración de la información para identificar su estructura, calidad y relevancia. Como resultado, se documentó detalladamente el estado de los datos disponibles en relación con los objetivos específicos OE1 y OE2.

3.3. Preparación de los datos

El procesamiento de los datos involucró la segmentación de imágenes mamográficas y la extracción de características radiómicas relevantes. Se aplicaron técnicas de limpieza, normalización y verificación para obtener un conjunto de datos adecuado para el modelado. Como resultado, se obtuvo un conjunto de características radiómicas optimizado mediante selección de características relevantes, tanto del preprocesamiento de imágenes como del archivo CSV proporcionado. La reducción de características mantuvo la capacidad predictiva del modelo sin afectar su desempeño, se documentó completamente el pipeline de preprocesamiento, y se confirmó el cumplimiento de los objetivos específicos OE1 y OE2.

3.4. Modelado

Se abordó el desarrollo de modelos de inteligencia artificial mediante la selección y configuración de algoritmos tradicionales de *machine learning*. Se realizó el ajuste de hiperparámetros y se aplicó validación cruzada para garantizar la robustez de los modelos. Como resultado, se entrenaron y

optimizaron modelos binarios y multiclase. Además, todo el proceso experimental y los resultados fueron registrados para asegurar la trazabilidad, cumpliendo así con el objetivo OE3.

3.5. Evaluación

La medición del desempeño se efectuó mediante el cálculo de métricas claves (*Accuracy*, *Recall*, *Precision*, *F1-score*) en tres contextos, conjunto ciego derivado del CSV (datos de entrenamiento), mamografías DICOM de FVL, y dataset público de RSNA. Posteriormente se realizó la comparación entre los distintos modelos implementados, así como también la comparación con el estado del arte. Todas las etapas del proceso desde la selección de métricas hasta la interpretación de resultados fueron validadas en conjunto con el asesor técnico Juan Felipe Orejuela, ingeniero biomédico, quien proporcionó retroalimentación continua sobre cada etapa y decisión tomada. Como resultado de este análisis comparativo, se identificaron y validaron los modelos óptimos de clasificación binaria y multiclase en cada escenario, determinando su desempeño real y capacidad de generalización, cumpliendo así con el objetivo OE4.

3.6. Desarrollo Web

Se diseñó e implementó una aplicación web funcional construida con Vue.js y Flask, integrando todo el pipeline de procesamiento. La implementación incluyó la elaboración de un *pipeline* automatizado con Watchdog para monitorear directorios de entrada, el desarrollo del *backend* para comunicación con modelos entrenados, y del *frontend* para la carga de imágenes y la visualización de resultados con niveles de confianza, y por último, la generación de reportes HL7 compatibles con sistemas PACS hospitalarios. Tras pruebas de funcionalidad y usabilidad, se obtuvo una aplicación completamente operacional que encapsula el flujo completo de análisis, cumpliendo así con el objetivo OE5.




Ilustración 2. Diagrama de la metodología

4. PRESENTACIÓN DE LA PROPUESTA

La propuesta desarrollada en este proyecto se organiza siguiendo una metodología CRISP-DM adaptada, que integra las fases de comprensión del negocio y de los datos, preparación de los datos, modelado de algoritmos de *Machine Learning*, evaluación de los modelos e implementación de una aplicación web. lo que permitió abordar el problema de clasificación de la densidad mamaria de manera estructurada y progresiva. A partir de una comprensión detallada del contexto clínico y de las necesidades definidas por la Fundación Valle del Lili, el trabajo avanzó de forma incremental, iniciando con modelos base sencillos y evolucionando hacia enfoques más complejos para identificar aquel que ofreciera el mejor desempeño. Además del desarrollo de los modelos predictivos, se incorporó un componente funcional que incluye una interfaz web, un pipeline automatizado de procesamiento y un módulo para la generación de mensajes HL7, orientado a evidenciar visualmente cómo operaría el flujo de procesamiento en una implementación real.

4.1. Comprensión del negocio

Durante esta fase se realizaron múltiples reuniones con el asesor técnico del proyecto, en las que se recolectó información sobre las etapas necesarias para la clasificación de una mamografía y las estrategias para abordar el problema. Se definió que los datos proporcionados por parte de la FVL para entrenar los modelos sería un archivo CSV con los registros de características radiómicas de las mamografías junto con diez mamografías de la FVL para la validación del producto final.

En esta fase se acordó implementar tanto una clasificación multiclase (A, B, C y D) como una clasificación binaria (no denso/denso). En el segundo caso, se agruparon las categorías C y D bajo el rótulo de “denso”. Esta decisión responde al problema clínico en la detección temprana de casos complejos que requieren remisión a estudios complementarios. Desde la perspectiva técnica, el modelo binario permite aprovechar mejor la distribución de los datos y reducir la dispersión de las clases. Además, la división no denso/denso es seguida por dos clasificadores binarios adicionales: uno que diferencia entre A y B cuando el caso es no denso, y otro que distingue entre C y D cuando el caso es denso.

También se consideró la explicabilidad de los modelos como un punto clave para tomar decisiones sobre el preprocesamiento y el entrenamiento. Aunque esto limita algunas técnicas posibles, favorece el

ámbito médico al garantizar decisiones transparentes y éticas que impactan directamente en la vida y el bienestar de las pacientes.

Se determinó como relevante considerar si las mamografías corresponden a la proyección CC (craneocaudal) o MLO (medio lateral oblicua), ya que en esta última el músculo pectoral puede afectar el cálculo de las características radiómicas, lo que exige una segmentación distinta para cada proyección. Dado que el conjunto de datos proporcionado por la Fundación Valle del Lili incluye en su mayoría mamografías CC sin implantes y que en los estudios mamográficos siempre se toman al menos las imágenes en proyección CC, las futuras pruebas con nuevos datos se realizan bajo los mismos criterios para mantener la consistencia.

Para evaluar el desempeño del modelo se definieron como métricas principales el *Accuracy* y el *F1-score*. El *Accuracy* permite medir el porcentaje de predicciones correctas y realizar una comparativa directa con la iteración previa del proyecto desarrollada por la UAO y con otros de los proyectos recopilados en el estado del arte. El *F1-score* pondera la proporción de aciertos entre las diferentes clases (*Precision* y *Recall*), ofreciendo una perspectiva más objetiva del modelo y ayudando a mitigar el desbalance entre las clases presentes en el conjunto de datos. Además, se acordó que el modelo denso/no denso deberá alcanzar al menos un 85% de *Accuracy* y *F1-score*, como criterio mínimo esperado de desempeño.

Adicionalmente, se identificó la necesidad de desarrollar dos componentes, primero, una interfaz gráfica amigable que permita la interacción con el modelo y la comprensión de sus resultados, así mismo, un módulo capaz de generar mensajes en formato HL7 que contengan el identificador del paciente, el estudio realizado y las observaciones obtenidas a través del modelo, siendo compatible con la infraestructura médica existente.

4.2. Comprensión de los datos

En esta fase se realizó el análisis exploratorio de un conjunto de imágenes médicas de validación en formato DICOM y del archivo CSV con características radiómicas previamente extraídas. Para el preprocesamiento se utilizaron las bibliotecas Pydicom para la lectura de archivos DICOM, PyRadiomics para la extracción de características radiómicas de las imágenes, y *pandas* para el análisis del conjunto de datos tabular.

El conjunto de imágenes está compuesto por 14 mamografías digitales 2D de 5 pacientes: 10 proyecciones CC y 4 MLO. La distribución de densidades mamarias BI-RADS de estas pacientes es: 2 con densidad C, 2 con densidad B y 1 con densidad D. A continuación, se muestra la distribución de las imágenes en proyección CC por cada tipo de densidad:




Ilustración 3. Diagrama de distribución de densidades en conjunto de imágenes de la FVL

Por otra parte, el conjunto de datos tabulares contiene 2.372 registros, cada uno correspondiente a una mamografía con sus características radiómicas extraídas. El dataset incluye 104 variables numéricas que representan características radiómicas, además de una variable categórica "Mammography_Equipment" que identifica el equipo de adquisición, y la variable objetivo "Tipo_Tejido" con la clasificación de densidad. No se encontraron valores nulos en este conjunto de datos. A continuación, se muestra la distribución de los registros radiómicos por cada tipo de densidad:




Ilustración 4. Diagrama de distribución de densidades en archivo CSV

Las características extraídas por la FVL se agrupan en las siguientes familias radiómicas, las cuales permiten describir distintos aspectos del tejido y aportar una visión más completa de su fenotipo:

- **Shape2D:** describe la forma y geometría de la región analizada, como área o perímetro.
- **First Order:** mide propiedades estadísticas básicas de la intensidad de los píxeles, como media, desviación estándar o asimetría.
- **GLCM (Gray Level Co-occurrence Matrix):** captura la textura mediante la relación espacial entre los niveles de gris.
- **GLRLM (Gray Level Run Length Matrix):** evalúa patrones de textura considerando secuencias consecutivas de píxeles con la misma intensidad.
- **GLSZM (Gray Level Size Zone Matrix):** analiza la distribución de zonas con intensidades homogéneas dentro de la imagen.
- **GLDM (Gray Level Dependence Matrix):** mide la dependencia entre píxeles con intensidades similares.

- **NGTDM (Neighborhood Gray Tone Difference Matrix):** cuantifica las diferencias de intensidad entre un píxel y su vecindario, proporcionando información sobre contraste local.

De forma adicional, se exploraron datasets públicos con el fin de probar el pipeline completo, desde la extracción de características radiómicas hasta el entrenamiento del modelo. La disponibilidad de mamografías DICOM públicas es muy limitada: solo se identificaron tres conjuntos accesibles y, entre ellos, se seleccionó “Screening Mammography Breast Cancer Detection” de la RSNA, disponible en *Kaggle*, por presentar la mejor distribución de clases. Aunque el dataset original contiene 5706 mamografías, tras descartar las imágenes en proyección MLO, aquellas con implantes y las que no contaban con etiqueta de densidad, se obtuvieron 13 598 imágenes distribuidas de la siguiente manera.




Ilustración 5. Diagrama de distribución de densidades en conjunto de imágenes de la RSNA

4.3. Preparación de los datos

Este proceso incluye varias etapas para limpiar, transformar y estructurar los datos en un formato adecuado para su análisis, tanto para las imágenes y el archivo CSV de radiómicos de la FVL como para el conjunto de imágenes de la RSNA, además de seleccionar las características que se utilizarán en el entrenamiento.

4.3.1. Preparación del archivo CSV proporcionado por la FVL:

Como parte del análisis exploratorio se descartaron variables que podrían comprometer la generalización del modelo. En primer lugar, se eliminó la columna "Mammography_Equipment", la cual indica el equipo utilizado para la adquisición de la imagen y presenta únicamente 2 categorías, lo que podría limitar la capacidad del modelo para ser usado con diferentes equipos de mamografía.

Adicionalmente, se excluyeron todas las variables de la familia Shape2D, dado que en su mayoría representan medidas geométricas del seno como área, perímetro o longitud. Puesto que no existe evidencia clínica que respalde la influencia del tamaño del seno en la densidad mamaria, y siguiendo la recomendación del asesor técnico, se determinó que la inclusión de estas variables podría introducir ruido asociado a características morfológicas no relevantes para la predicción.

Además, la columna objetivo "Tipo_Tejido", con valores A, B, C y D, fue mapeada a representaciones numéricas (0, 1, 2 y 3). También se creó un segundo conjunto de datos donde se agrupó la columna objetivo en no denso (Categorías A y B como 0) y denso (Categorías C y D como 1), con el fin de facilitar la clasificación binaria y mejorar la precisión de las predicciones.

Así mismo, se evaluó la normalización de las variables numéricas con el fin de estandarizar su escala y favorecer la estabilidad del proceso de aprendizaje. Se compararon dos técnicas: *StandardScaler* (estandarización basada en media y desviación estándar) y *MinMaxScaler* (escalamiento al rango de 0 a 1). En las pruebas preliminares no se observaron diferencias significativas en el desempeño de los modelos entre ambos métodos. Sin embargo, se seleccionó *StandardScaler* al ser una técnica con mayor compatibilidad en modelos basados en distancias (como SVM), los cuales se benefician de variables con distribución aproximadamente normal y varianza homogénea.

No se eliminaron valores atípicos siguiendo la recomendación del asesor técnico y, en su lugar, se enfocaron los esfuerzos en mitigar la multicolinealidad mediante una nueva selección de características. Usando el cálculo del coeficiente de correlación de Pearson entre predictores, se identificaron pares de variables con correlaciones iguales o superiores al 95%, conservando en cada caso la variable con mayor puntaje de información mutua respecto a la variable objetivo. Posteriormente, se evaluaron dos configuraciones: un modelo con selección basada en VIF, métrica utilizada para cuantificar el aumento de la varianza de un coeficiente de regresión cuando una variable está correlacionada con otras del modelo.

Se aplicó un umbral de VIF igual a 10, que resultó en la selección de 8 predictores, y un modelo sin aplicación de VIF que conservó los 39 predictores originales.

En los modelos con selección VIF, la clasificación no denso/denso alcanzó un desempeño promedio del 85% en las métricas evaluadas, lo que evidencia que 8 variables son suficientes para asegurar un rendimiento significativo tanto en modelos simples como Regresión Logística como en modelos más complejos como SVM y XGBoost, mientras que en la clasificación multiclase el desempeño promedio fue del 70% (menor que en el caso binario, pero aún prometedor dada la mayor complejidad del problema). Las variables seleccionadas en ambos escenarios fueron las siguientes:

Tabla 2. Variables seleccionadas por VIF para los modelos binario y multiclase

Variables	Modelo binario	Modelo multiclase
<i>LargeAreaLowGrayLevelEmphasis</i>		X
<i>LongRunLowGrayLevelEmphasis</i>	X	
<i>Kurtosis</i>	X	X
<i>Contrast</i>	X	X
<i>Coarseness</i>	X	X
<i>Busyness</i>	X	X
<i>ClusterProminence</i>	X	X
<i>Skewness</i>	X	X
<i>Minimun</i>	X	X

Al incorporar los 39 predictores sin aplicar VIF, el modelo de clasificación no denso/denso alcanzó un desempeño promedio del 87.5%, lo que representa una mejora de aproximadamente 2.5 puntos porcentuales frente al modelo con 8 predictores, aunque a costa de incluir 31 variables adicionales. En el caso de la clasificación multiclase, la inclusión de los 39 predictores también mejoró las métricas, elevándolas a un rango entre 72% y 75%, es decir, un aumento de 3 a 8 puntos porcentuales respecto al modelo con VIF, lo que demuestra que las variables adicionales contienen información relevante para la clasificación multiclase, aunque en proporciones menores que los 8 predictores principales.

Considerando este balance entre la mejora en desempeño y el incremento de la complejidad del modelo, se decidió utilizar el conjunto completo de 39 predictores sin aplicación de VIF para el desarrollo final.

Debido al desbalance entre clases, se consideró utilizar SMOTE para aumentar la clase minoritaria. Sin embargo, en las pruebas preliminares con SVM se observó un deterioro del *F1-score* de 2.41% en la clasificación no denso/denso y de 6.8% en la clasificación multiclase al aplicarlo. Además, el asesor técnico indicó que, por tratarse de un modelo de uso médico, era preferible evitar datos sintéticos en el entrenamiento, por lo que esta opción fue descartada.

Previo al entrenamiento, los conjuntos de datos se partitionaron en subconjuntos de entrenamiento y validación conservando la estratificación de la variable objetivo para mantener la proporción de clases en ambos conjuntos. Se llevaron a cabo pruebas con diferentes proporciones (85-15, 80-20, 75-25 y 70-30), identificando que para la clasificación no denso/denso la mejor partición fue 70-30, mientras que para la clasificación multiclase fue 75-25.

4.3.2. Preparación de las imágenes proporcionadas por la FVL para validación:

Una vez definido el procesamiento sobre el archivo CSV y sus características radiómicas, se procedió a trabajar directamente con las imágenes proporcionadas por la FVL. Dado que se desconocía el preprocesamiento exacto aplicado a las imágenes para generar las características radiómicas del archivo, se realizaron diversas pruebas experimentales para identificar el flujo que ofrecía resultados más consistentes con esos datos. El preprocesamiento seleccionado consistió en:

- **Recorte de regiones con texto (Segmentación):** mediante OpenCV se identificó y aisló la región mamaria principal, eliminando el fondo oscuro y las etiquetas de lateralidad. El proceso aplicó umbralización automática con el método de Otsu sobre una versión temporalmente normalizada, seguido de *findContours* (modo RETR_EXTERNAL, método CHAIN_APPROX_SIMPLE) para identificar el contorno más grande correspondiente al tejido mamario y generar una máscara binaria. La imagen original se preservó en formato *float64* sin modificaciones de intensidad, garantizando que las características radiómicas se extrajeran de los valores de píxel originales del DICOM.

Adicionalmente, se exploró el uso de Segment Anything Model (SAM) para segmentar el músculo pectoral en proyecciones MLO, obteniendo resultados prometedores en la delimitación del tejido

mamario. Sin embargo, su alto costo computacional, la necesidad de GPU para ejecución eficiente y el enfoque del proyecto en datos de la FVL (sin imágenes MLO etiquetadas) llevaron a descartar su implementación.

- **Extracción de características radiómicas:** se utilizó PyRadiomics versión 3.1, mediante un script en Python basado en la clase *RadiomicsFeatureExtractor* y un archivo de configuración en formato YAML, cargando como entrada cada una de las imágenes originales y su correspondiente máscara previamente extraída. Se empleó la siguiente configuración de parámetros (elegidos al ofrecer la mayor similitud con los radiómicos del CSV):
 - *binWidth*: 25 (ancho de intervalo para discretización de intensidades)
 - *normalize*: *false* (sin normalización interna)
 - *force2D*: *true* (extracción forzada en 2D)
 - *force2Ddimension*: 0 (procesamiento por proyección individual)

Los parámetros no especificados se mantuvieron con los valores por defecto de PyRadiomics. Se extrajeron las familias de características GLCM, GLRLM, GLSZM, GLDM, NGTDM y *First Order*, resultando en un total de 94 características radiómicas, las cuales fueron almacenadas para todas las imágenes en un archivo CSV.

- **Estandarización:** Se aplicó el transformador *Standard Scaler*.

4.3.3. Preparación de imágenes de la RSNA:

Ya teniendo definido el flujo de preprocesamiento sobre las imágenes proporcionadas por la FVL, se procedió a realizar la preparación del conjunto de imágenes público de la RSNA. En este conjunto se realizó el siguiente flujo:

- Las imágenes fueron cargadas como matrices de píxeles y normalizadas para unificar la intensidad de brillo entre equipos de adquisición distintos.
- La segmentación siguió el mismo procedimiento utilizado en las imágenes de la FVL. Posteriormente, se probó CLAHE para mejorar el contraste. En las pruebas preliminares con XGBoost, la aplicación de contraste incrementó el *F1-score* en un 0.26% para la clasificación multiclase, por lo que esta técnica se incorporó de manera definitiva al preprocesamiento.

- Para la extracción de características radiómicas se utilizó la misma configuración aplicada al conjunto de la FVL. Adicionalmente, se generaron dos versiones del conjunto de características: una con características *Wavelet* (transformaciones que descomponen la imagen en distintos niveles de detalle para resaltar texturas y bordes) y otra sin ellas, con el fin de comparar su impacto en el desempeño. La versión con *Wavelet* produjo 279 características y, tras el procesamiento, se conservaron 98 predictores. La versión sin *Wavelet* generó 98 características iniciales, de las cuales se conservaron 37 predictores. Ambos conjuntos fueron almacenados como archivos CSV (que fueron procesados de la misma forma que el CSV de la FVL).

4.4. Modelado

En la etapa de modelado se evaluaron cinco modelos de clasificación para predecir la densidad mamaria: **Regresión logística, SVM, AdaBoost, XGBoost y Pytorch Tabular**. Los cuatro primeros modelos se implementaron utilizando la librería *Scikit-learn*, una de las librerías más populares de aprendizaje automático. La optimización de hiperparámetros se realizó mediante GridSearchCV con validación cruzada de 5 folds, que permite evaluar combinaciones de parámetros para encontrar la mejor configuración. Para PyTorch Tabular se usó la librería del mismo nombre y su ajuste se llevó a cabo con Optuna, un *framework* especializado en optimización automática de hiperparámetros.

Para cada una de las cinco opciones de modelado se construyeron dos variantes utilizando el conjunto de datos de la FVL: un modelo binario (no denso/denso) y un modelo multiclase. Adicionalmente, se entrenaron modelos específicos para la clasificación (A/B) y (C/D) tanto con XGBoost como con AdaBoost. Finalmente, con XGBoost se desarrollaron también un modelo binario (no denso/denso) y uno multiclase utilizando el conjunto de datos de la RSNA, con el fin de comparar el desempeño entre distintas fuentes de datos.

A continuación, se describe brevemente cada uno de los modelos, junto con los mejores hiperparametros encontradas para cada uno:

El primer modelo fue **Regresión Logística**, elegido por su simplicidad y alta interpretabilidad. Permite entender fácilmente cómo influye cada variable en el resultado mediante los *Log-Odds*, lo que la hace

ideal cuando se busca transparencia en las decisiones del modelo. Sin embargo, su principal limitación es que asume relaciones lineales entre las variables y la respuesta.

Tabla 3. Hiper Parámetros óptimos para Regresión Logística

Parámetro	No denso/denso	Multiclase
Penalty	l1	l1
C	1.5	45
tol	0.0004	0.03

El segundo modelo fue una Máquina de Vectores de Soporte (**SVM**), seleccionada por su capacidad para manejar relaciones no lineales a través del uso de kernels. Es un modelo robusto que suele ofrecer muy buen desempeño en problemas complejos, aunque su entrenamiento puede ser costoso cuando el conjunto de datos es grande.

Tabla 4. Hiper Parámetros óptimos para SVM

Parámetro	No denso/denso	Multiclase
Kernel	rbf	rbf
C	2.5	30
tol	0.16	1.0
gamma	0.007	0.018

El tercer modelo fue **AdaBoost**, implementado con árboles de decisión, siguiendo la recomendación del asesor técnico de la FVL. Este modelo combina múltiples clasificadores débiles para formar uno más

fuerte, mejorando la precisión y reduciendo el sesgo. Su principal desventaja es que puede ser sensible a los datos atípicos.

Tabla 5. Hiper Parámetros óptimos para AdaBoost

Parámetro	No denso/denso	Multiclase
n_estimators	400	300
learning_rate	0.3	0.047
max_depth	5	5
criterion	entropy	gini
min_samples	4	2
min_samples_leaf	1	3
max_features	sqrt	sqrt
min_impuriti_decrease	0	0

El cuarto modelo fue **XGBoost**. Este algoritmo de boosting fue seleccionado por su eficiencia en tareas con datos tabulares. Además, incluye técnicas integradas de regularización, aunque su entrenamiento puede requerir una cuidadosa optimización de hiperparámetros.

Tabla 6. Hiper Parámetros óptimos para XGBoost

Parámetro	No denso/denso	Multiclase
n_estimators	100	100
learning_rate	0.3	0.3
max_depth	3	3

subsample	1.0	0.6
colsample_bytree	1.0	1.0
gamma	0.5	0.1
min_child_weight	3	3
reg_alpha	1.0	0.6
reg_lambda	0.6	0.5

Finalmente, el quinto modelo fue *PyTorch Tabular*. Este algoritmo fue seleccionado ya que su enfoque permite aplicar redes neuronales profundas a datos estructurados, aprovechando su capacidad para aprender relaciones complejas y no lineales. No obstante, su principal desafío es la necesidad de mayor poder computacional y un ajuste más cuidadoso para evitar sobreajuste.

Tabla 7. Hiper Parámetros óptimos para PyTorch Tabular

Parámetro	No denso/denso	Multiclase
learning_rate	0.0071	0.000059
batch_size	512	256
dropout	0.49	0.26
layers	256-128	2048-1024-512-256-128
activation	LeakyReLU	ReLU
weight_decay	0.0072	0.00039

4.5. Evaluación

En esta sección se presentan los resultados de la evaluación de los modelos desarrollados para la clasificación de la densidad mamaria, tanto en su versión binaria (no denso/denso) como multiclase. Primero, se exponen las métricas obtenidas con el conjunto de prueba del CSV de la FVL para ambas configuraciones. Luego, se describe el comportamiento de los modelos al aplicarlos a mamografías externas de la FVL y de la RSNA. Posteriormente, se analiza el desempeño de los modelos entrenados y evaluados con el conjunto de la RSNA. Finalmente, se examina la interpretabilidad aportada por los valores de *Log-Odds*.

4.5.1. Evaluación de los modelos con el conjunto de prueba del CSV

Luego de definir los modelos candidatos, se procedió a evaluar su desempeño mediante diferentes métricas. En un primer momento, se empleó el *Accuracy* como métrica base, dado que es la más utilizada en la literatura revisada y proporciona un punto de comparación inicial, este nos indica el porcentaje de mamografías correctamente clasificadas según su categoría de densidad. No obstante, esta métrica resulta insuficiente en el contexto médico, particularmente en presencia de clases desbalanceadas o cuando ciertos errores de clasificación conllevan un mayor riesgo diagnóstico. En este proyecto, los falsos negativos de la clasificación binaria (mamografías con tejido denso clasificadas erróneamente como no densas) constituyen el fallo más crítico, ya que podrían generar una falsa sensación de seguridad y retrasar decisiones clínicas oportunas. Por ello, se dio mayor relevancia a las métricas de *Recall* (para la clasificación no denso/denso indica el porcentaje de mamografías con tejido denso que el modelo clasifica correctamente), *Precision* (para el modelo no denso/denso indica qué proporción de las mamografías que el modelo predice como densas realmente lo son) y especialmente al *F1-score*, que ofrece un equilibrio entre ambas.

A continuación, se muestran las métricas de los cinco modelos para la clasificación no denso/denso con la configuración óptima de hiperparámetros encontrada:

Tabla 8. Métricas de los modelos no denso/denso

Modelo	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
Regresión Logística	87.50%	86.53%	85.75%	86.11%
SVM	88.62%	88.00%	86.70%	87.29%
AdaBoost	89.04%	88.11%	87.68%	87.89%
XGBoost	88.90%	87.93%	87.57%	87.75%
<i>Pytorch Tabular</i>	86.80%	85.66%	85.12%	85.38%

En la clasificación binaria, AdaBoost y XGBoost presentaron los mejores resultados globales, con F1-scores de 87.89% y 87.75%, respectivamente. Estos valores reflejan un equilibrio adecuado entre Recall y Precision, lo que se traduce en una menor probabilidad de incurrir en falsos negativos sin aumentar excesivamente los falsos positivos. Sin embargo, las diferencias entre los modelos son relativamente pequeñas, lo que sugiere que, con el conjunto de datos disponible, todos alcanzan un desempeño similar y se aproximan al límite de su capacidad predictiva.

Para la clasificación de tipo A/B y C/D se decidió usar los dos modelos que mejores métricas mostraron en la clasificación no denso/denso: XGBoost y AdaBoost. A continuación, se presentan las métricas de ambos modelos y las matrices de confusión de XGBoost.

Tabla 9. Métricas de los modelos A/B

Modelo	<i>Accuracy</i>	<i>F1-score</i>
XGBoost	90.16%	78.54%
AdaBoost	90.41%	78.56%




Ilustración 6. Matriz de confusión del modelo A/B con XGBoost

Tabla 10. Métricas de los modelos C/D

Modelo	<i>Accuracy</i>	<i>F1-score</i>
XGBoost	85.58%	75.85%
AdaBoost	85.10%	75.30%




Ilustración 7. Matriz de confusión del modelo C/D con XGBoost

Los resultados muestran que **XGBoost** y **AdaBoost** tienen un desempeño prácticamente indistinguible, con diferencias en *F1-score* del 0.02% en A/B y del 0.55% en C/D, lo que sugiere que ambos algoritmos alcanzan un límite similar de rendimiento para esta tarea. Esto también implica que el comportamiento observado probablemente depende más del conjunto de datos y la dificultad del problema que del modelo específico utilizado.

Asimismo, las matrices de confusión (Ilustración 6 y 7) evidencian que las clases A y D presentan los mayores niveles de error. Dado su bajo nivel de acierto, el modelo no puede utilizarse con confianza para distinguir A de B ni D de C, siendo probable que esto se relacione con el desbalanceo de clases, ya que las categorías extremas suelen tener menor representación y el modelo no logra aprender patrones suficientemente robustos para ellas.

Tras analizar los resultados individuales, se decidió implementar un ensamble basado en modelos XGBoost, aprovechando sus tiempos de predicción más rápidos. En este enfoque, el ensamble se configura como un clasificador multiclase: primero, el modelo denso/no denso actúa como mediador, separando las

mamografías en grupos densos y no densos. Luego, las mamografías no densas se clasifican con el modelo A/B y las densas con el modelo C/D. Este ensamble se evalúa para comparar su desempeño con el resto de los modelos multiclase.

A continuación, se presenta una tabla comparativa con las métricas de todos los modelos multiclase configurados con sus hiperparámetros óptimos.

Tabla 11. Métricas de los modelos multiclase

Modelo	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
Regresión Logística	74.37%	73.26%	60.23%	64.53%
SVM	75.89%	74.44%	63.56%	67.52%
AdaBoost	76.05%	76.59%	62.85%	67.54%
XGBoost	78.92%	77.89%	68.24%	71.90%
<i>Pytorch Tabular</i>	72.18%	69.44%	58.37%	62.24%
Ensamble	76.05%	73.69%	65.68%	68.88%

En la clasificación multiclase, se observa una mayor diferenciación en el desempeño de los modelos que en la clasificación binaria. En este caso, **XGBoost** sobresale respecto a los demás, con un *Recall* de 68.24% y un *F1-score* de 71.90%. Mientras que los valores obtenidos por el resto de los modelos, se mantienen en rangos más bajos (por ejemplo, AdaBoost con *Recall* de 62.85% y *F1-score* de 67.54%). Esto indica que XGBoost logra captar mejor las diferentes clases presentes en el conjunto de datos, mostrando una capacidad predictiva superior en este escenario de clasificación multiclase.

Si bien el ensamble obtuvo resultados superiores al segundo mejor modelo individual (alcanzó un *F1-score* de 68.88% frente al 67.54% de AdaBoost), su desempeño sigue siendo insuficiente para igualar a XGBoost. La propagación del error desde el primer clasificador limita la ganancia conjunta y reduce el efecto esperado de combinar modelos.

Ahora se presenta la matriz de confusión para el modelo XGBoost multiclase, seleccionado con anterioridad como el de mejor desempeño. Aquí se puede visualizar de manera más detallada y precisa el comportamiento del modelo en la predicción de cada clase dentro del conjunto de datos.




Ilustración 8. Matriz de confusión del modelo XGBoost multiclase

La matriz de confusión del modelo XGBoost multiclase muestra que la categoría B presenta el mejor desempeño, con 89.0% de aciertos. Sin embargo, existe una confusión notable con la categoría C, 7.6% de las instancias de B fueron clasificadas como C y 21.7% de las instancias reales de C fueron predichas como B. Este último caso representa un falso negativo para tejido denso, dado que mamografías densas fueron clasificadas como no densas, lo cual constituye el error más crítico desde el punto de vista clínico. La categoría A es la más difícil para el modelo, con solo 45.8% de aciertos y un 52.5% clasificado erróneamente como B. Finalmente, en la categoría D el 63.0% de las instancias fueron clasificadas correctamente, mientras que 32.6% se confundieron con la categoría C.

Lo anterior sugiere que el modelo tiene grandes dificultades para distinguir las densidades A y D. Este comportamiento puede estar relacionado con el desbalance en el conjunto de datos. Lo que indica que el modelo no logra clasificar con suficiente confianza las clases minoritarias.

4.5.2. Evaluación de los modelos con imágenes de la FVL

Tras identificar los modelos con mejores métricas para cada tipo de clasificación usando el conjunto CSV, se evaluaron las 10 mamografías en proyección CC proporcionadas por la FVL con los tres modelos más destacados (SVM, XGBoost y AdaBoost), tanto para la clasificación no denso/denso como para el multiclase, a fin de estimar su desempeño real. A continuación, se detalla su comportamiento:

Tabla 12. Métricas de los modelos evaluados con mamografías de la FVL

Tipo de clasificación	Modelo	<i>Accuracy</i>	Tiempo promedio de clasificación (s)	Errores
No denso/denso	SVM	60.00%	0.001160	4
	AdaBoost	80.00%	0.133356	2
	XGBoost	60.00%	0.006059	4
Multiclase	SVM	40.00%	0.001107	6
	AdaBoost	60.00%	0.106698	4
	XGBoost	80.00%	0.001718	2

En la clasificación binaria, **AdaBoost** se destacó como el modelo con el mejor desempeño, logrando un 80% de acierto. Sin embargo, este alto rendimiento tuvo un costo significativo en el tiempo de inferencia, siendo 22 veces más lento que XGBoost y 115 veces más lento que SVM. Sus errores fueron

mínimos: un falso negativo (imagen densa clasificada como no densa) y un falso positivo (imagen no densa clasificada como densa).

Por su parte, SVM presentó el menor tiempo de inferencia, lo que lo hace atractivo desde una perspectiva computacional; sin embargo, incurrió en un mayor número de errores, principalmente falsos positivos. Aunque estos errores son menos críticos que los falsos negativos, pueden aumentar la carga de evaluación clínica.

Para la clasificación multiclase, el modelo **XGBoost** logró el mejor desempeño, alcanzando un 80% de acierto con un tiempo de inferencia solo 1.55 veces superior al de SVM. Sus errores fueron únicamente dos clasificaciones de categoría B como C. SVM registró el rendimiento más bajo, con solo un 40% de acierto y el mayor número de errores al clasificar incorrectamente mamografías B y D como C.

4.5.3. Evaluación de los modelos con imágenes de la RSNA

Al igual que como se realizó con las 10 mamografías otorgadas por la FVL, se hizo una validación con 20 imágenes del conjunto de datos público de la RSNA para comparar la efectividad de tres modelos binarios y multiclase (SVM, AdaBoost y XGBoost). En esta prueba, el modelo binario AdaBoost presentó el mejor desempeño con una *Accuracy* de 80% y tiempos de ejecución de 0.06 segundos en promedio. Los modelos XGBoost y SVM binarios también mostraron resultados aceptables. Sin embargo, todos los modelos multiclase obtuvieron puntajes considerablemente inferiores (menos del 40% de *Accuracy*).

4.5.4. Elección de los mejores modelos: AdaBoost para no denso/denso y XGBoost para multiclase

La selección final de modelos se basó en el rendimiento obtenido tanto en el conjunto de prueba como en la evaluación independiente realizada con mamografías de la FVL. En la tarea binaria, AdaBoost alcanzó las mejores métricas en el conjunto de prueba, con una *Accuracy* de 89.04%, *Recall* de 87.68% y *F1-score* de 87.89%, superando ligeramente a XGBoost (88.90% de *Accuracy* y 87.75% de *F1-score*). Esta diferencia, aunque pequeña, se mantuvo en la validación externa: AdaBoost obtuvo 80% de

Accuracy, mientras que XGBoost alcanzó 60% de *Accuracy*. Esta consistencia entre escenarios justificó elegir a AdaBoost como el modelo binario final.

En la clasificación multiclase, XGBoost presentó el mejor comportamiento en el conjunto de prueba, con una *Accuracy* de 78.92%, *Recall* de 68.24% y *F1-score* de 71.90%. Esta superioridad se mantuvo en el conjunto de validación con imágenes de la FVL, donde XGBoost obtuvo 80% de *Accuracy*, mientras que AdaBoost llegó solo a 60%.

4.5.5. Resultados de evaluación sobre el dataset de la RSNA

Como se indicó en la fase de preparación de datos, se generaron dos archivos CSV con las características radiómicas de las imágenes provenientes de la base de datos de la RSNA: uno con características *Wavelet* y otro sin ellas. El objetivo fue comparar el desempeño entre ambas opciones y evaluar los resultados sobre un conjunto de datos que pasó por todo el pipeline de procesamiento de imagen. A continuación, se presenta una tabla con las métricas obtenidas utilizando los mejores modelos elegidos.

Tabla 13. Métricas de AdaBoost y XGBoost con mamografías de la RSNA

Tipo de clasificación	Transformación <i>Wavelet</i>	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
No denso/denso (AdaBoost)	Sí	85.37%	85.37%	85.27%	85.31%
	No	83.86%	83.82%	83.81%	83.81%
Multiclase	Sí	72.17%	69.62%	59.12%	62.67%

(XGBoost)	No	70.97%	67.64%	57.61%	60.96%
-----------	----	--------	--------	--------	--------

Las métricas muestran que la inclusión de características *Wavelet* produjo resultados superiores en ambos escenarios de clasificación. Para no denso/denso, la inclusión de *Wavelet* produjo una mejora del 1.50% en el *FI-score*. En la clasificación multiclase, la mejora fue del 1.71%. Aunque las mejoras son moderadas, confirman que la descomposición multiescala aporta información adicional útil para resaltar texturas y patrones relevantes en las mamografías.

Sin embargo, pese a la ventaja de *Wavelet*, el rendimiento general fue considerablemente inferior al obtenido con el conjunto de la FVL, especialmente en la clasificación multiclase. Esto resulta llamativo dado que la base de datos de la RSNA contiene un volumen mucho mayor de imágenes. Una posible explicación es la alta variabilidad entre dispositivos de adquisición, ya que las mamografías provienen de nueve máquinas distintas, lo que genera diferencias claramente visibles en iluminación y contraste. A pesar de las limitaciones de desempeño, los resultados obtenidos indican que el pipeline completo de procesamiento de imágenes, extracción de características y entrenamiento funciona correctamente, ya que fue capaz de procesar un conjunto de datos y producir métricas coherentes.

4.5.6. Interpretabilidad mediante análisis de Log-Odds para Regresión Logística

Si bien contar con buenos desempeños en las métricas de los modelos es fundamental, en un contexto clínico también se requiere comprender cómo y por qué el modelo toma sus decisiones. Por esta razón, además de identificar los modelos con mejor rendimiento predictivo, se le quiso dar importancia a la interpretabilidad que aporta la Regresión Logística para el modelo binario, puesto que sus métricas no están tan lejos de las alcanzadas por los mejores modelos.

Los *Log-Odds* (logaritmo de las probabilidades) representan el cambio en la razón de probabilidades de que una muestra pertenezca a una clase u otra por cada unidad de cambio en una característica. Un *Log-Odd* positivo indica que la característica aumenta la probabilidad de pertenecer a la clase positiva (tejido denso), mientras que un *Log-Odd* negativo la disminuye, favoreciendo la clase negativa (tejido no denso). Este análisis cuantifica el efecto de cada variable en la probabilidad de clasificación,

proporcionando así una perspectiva sobre qué características radiómicas contribuyen más a identificar tejido mamario denso. A continuación, se presentan las características un *Log-Odd* positivo.




Ilustración 9. *Ranking* de las 10 características radiómicas con mayor peso positivo según Log-Odds

En la Ilustración 9, podemos observar que la característica con mayor contribución positiva fue la energía total de primer orden (*Log-Odds* de 2.21), lo que indica que cuando el tejido presenta mayores valores de intensidad de manera concentrada, tiende a ser denso.




Ilustración 10. Ranking de las 10 características radiómicas con mayor peso negativo según Log-Odds

Para el caso de la ilustración 10, se observa que la característica con mayor contribución negativa fue la curtosis o kurtosis de intensidad (*Log-Odds* de -1.99), lo que sugiere que cuando la distribución de intensidades en la imagen presenta valores concentrados alrededor de la media con pocas variaciones extremas, el tejido tiende a ser no denso.

4.6. Desarrollo web

Una vez seleccionados y evaluados los modelos con mejor desempeño, fue necesario materializar su uso en un entorno cercano a la práctica clínica, de modo que, para demostrar el funcionamiento integral de la solución propuesta, se desarrollaron dos componentes complementarios: una aplicación web interactiva y un pipeline automatizado de procesamiento por lotes.

4.6.1. Aplicación Web

Se implementó una aplicación web utilizando **Vue.js** para el frontend y **Flask** para el backend, que permite ejecutar el flujo completo desde la carga de la imagen DICOM hasta la predicción de densidad mamaria. El sistema realiza las siguientes operaciones de manera secuencial:

1. **Validación de entrada:** Verifica automáticamente que la imagen corresponda a una proyección CC y que no presente implantes mamarios a través de **Pydicom**, ya que estas condiciones no estaban representadas en el conjunto de entrenamiento y podrían generar predicciones no confiables.
2. **Preprocesamiento:** Aplica segmentación de la región de interés con **OpenCV** y extracción de características radiómicas mediante **PyRadiomics** y el pipeline establecido en la fase de preparación de datos.
3. **Selección de características:** Filtra únicamente las características utilizadas durante el entrenamiento de los modelos, garantizando consistencia entre ambas fases.
4. **Predicción:** Ejecuta inferencia utilizando tanto el modelo binario (no denso /denso) como el modelo multiclase (BI-RADS), presentando el nivel de confianza asociado a cada predicción.

Se adjunta el enlace a un video con una demostración de la aplicación web, y así comprender su funcionamiento: [Webapp](#)

4.6.2. Pipeline Automatizado:

Adicionalmente, se implementó un sistema de procesamiento por lotes mediante Python y la biblioteca **Watchdog**, que monitorea continuamente un directorio de entrada. El pipeline acepta múltiples formatos: archivos DICOM individuales, carpetas conteniendo archivos DICOM, o archivos comprimidos (ZIP) con imágenes DICOM. Realiza las mismas operaciones que la aplicación web, pero incluye las siguientes etapas adicionales:

1. **Almacenamiento de radiómicos:** Los radiómicos generados se almacenan en un archivo CSV centralizado
2. **Registro de errores:** Todo error en cualquiera de las etapas se almacena en un archivo de logs.

3. **Generación de salida HL7:** Produce un mensaje estructurado en formato HL7 conteniendo los resultados de clasificación, facilitando la integración con sistemas de información hospitalaria.

Esta implementación permite visualizar una hipotética implementación de procesamiento masivo de estudios en un entorno clínico real.




Ilustración 11. Diagrama de infraestructura y flujo de trabajo del Pipeline automatizado.

4.6.3. Plan de pruebas

Como estos componentes hacen parte del funcionamiento práctico de la solución propuesta, para garantizar la calidad de esta, se diseñó un plan de pruebas que será ejecutado sobre la API y el pipeline. A continuación, se encuentra un resumen con las pruebas realizadas, describiendo el objetivo y resultado esperado de cada una. Asegurando coberturas sobre casos ideales, entradas incompletas o vacías y escenarios de fallo dentro de los servicios.

Tabla 14. Pruebas Realizadas

ID	Tipo	Categoría	Caso de Prueba	Criterio de Aceptación	Resultado Esperado	Estado
TC-01	Unitaria / API	Happy path	Archivo DICOM válido CC	Response time < 10s, código 200	Código 200: DataFrame JSON con 39 características	Aprobado
TC-02	Unitaria / API	Validación	Sin archivo adjunto	Respuesta inmediata con error claro	Código 400: "Missing file field 'dicom'"	Aprobado
TC-03	Unitaria / API - <i>Watchdog</i>	Validación	Archivo no-DICOM (ej: .jpg)	Detección de formato antes de procesamiento	Código 400: "Failed to parse DICOM"	Aprobado
TC-04	Unitaria / API - <i>Watchdog</i>	Manejo de errores	DICOM corrupto/truncado	Sistema no debe crashear	Código 400: "Failed to read uploaded file"	Aprobado
TC-05	Unitaria / API - <i>Watchdog</i>	Reglas de negocio	Vista MLO (no soportada)	Validación de metadatos DICOM	Código 400: "Only CC view is supported"	Aprobado
TC-06	Unitaria / API	Happy path	DataFrame válido para predicción	Ambos modelos ejecutados exitosamente	Código 200: Predicción binaria y multiclase	Aprobado
TC-07	Unitaria / API	Validación	Request sin JSON	Validación de Content-Type	Código 400 "Expected application/json with dataframe payload"	Aprobado
TC-08	Integración / <i>Watchdog</i>	Happy path	Generación HL7	Archivo .hl7 creado con estructura válida	Archivo .hl7 con metadata correcta	Aprobado
TC-09	Integración / API - Servicio	Manejo de errores	Imagen completamente negra	Error de segmentación capturado	Código 500: "Image segmentation failed (ZeroDivisionError)"	Aprobado
TC-10	Integración / API - Servicio	Manejo de errores	Configuración de radiómicos inválida	Error de extracción capturado	Código 500: "Radiomics extraction failed"	Aprobado
TC-11	Integración / API - Servicio	Manejo de errores	Modelo no encontrado	Error de clasificación capturado	Código 500: "FileNotFoundError: kbest_bin.txt"	Aprobado

5. VALIDACIÓN Y RESULTADOS OBTENIDOS

En primer lugar, las fases de preparación de datos y análisis exploratorio permitieron establecer el *pipeline* completo de procesamiento aplicado a las mamografías DICOM y registros radiómicos proporcionados por la Fundación Valle del Lili. Este flujo incluye la segmentación de las imágenes mamográficas y la extracción de características radiómicas a partir de las regiones de interés. Debido al desbalance entre clases, se consideró utilizar SMOTE para aumentar la clase minoritaria. Sin embargo, en las pruebas preliminares se observó un deterioro en el *F1-score*, por lo que esta opción fue descartada. Los conjuntos de datos fueron divididos en proporciones de 70-30 para la clasificación no denso/denso y 75-25 para la clasificación multiclase, puesto que demostraron los mayores desempeños entre los cuatro tipos evaluados (85-15, 80-20, 75-25 y 70-30).

Además, se identificó como óptima una selección de 39 características que logró reducir la complejidad computacional sin una pérdida significativa del desempeño de los modelos, siendo comparable al uso de los 97 predictores totales. Demostrando eficiencia sin sacrificar precisión, cumpliendo así con OE1 (preparar las mamografías para su procesamiento) y OE2 (procesar las características radiómicas).

Frente al diseño de los modelos, se evaluaron cinco opciones: Regresión Logística, SVM, AdaBoost, XGBoost y PyTorch Tabular, la configuración óptima de hiperparámetros para cada uno fue encontrada mediante búsquedas en malla. Tras la optimización, AdaBoost para clasificación binaria alcanzó un *F1-score* del 87.89% en el conjunto ciego de prueba (711 registros derivados del CSV original) superando el umbral del 85% establecido por la FVL. XGBoost para clasificación multiclase logró un *F1-score* del 71.90% en el conjunto ciego de prueba (593 registros derivados del CSV original). Estos resultados permiten dar cumplimiento al OE3 (diseñar y entrenar modelos de clasificación binaria y multiclase) y, al mismo tiempo, aportan al OE4 (evaluar el desempeño mediante métricas estándar) al validar el rendimiento del sistema en datos completamente nuevos.

AdaBoost alcanzó un 80% de *Accuracy* en el conjunto de validación de mamografías de la Fundación Valle del Lili no incluidas en el CSV (10 imágenes) y un 80% en el conjunto de imágenes externo RSNA *Screening Mammography Breast Cancer Detection* (20 imágenes). En este escenario, los errores observados incluyeron un número limitado de falsos negativos, manteniendo una adecuada capacidad de detección de tejido denso. XGBoost obtuvo un 80% de *Accuracy* en las mamografías de validación de la FVL y un 35% en el conjunto de validación de la RSNA, lo que refleja un buen desempeño en el contexto interno de la institución, pero también una limitada capacidad de generalización hacia datos externos

debido a diferencias en equipamiento y protocolos de adquisición. Por otro lado, la evaluación de tiempos de inferencia mostró que AdaBoost (binario) requirió en promedio 0.133 segundos por predicción, mientras que XGBoost (multiclase) procesó cada caso en 0.002 segundos en promedio, valores adecuados para un entorno clínico supervisado. En conjunto, las métricas de *Accuracy*, *Precision*, *Recall*, *F1-score* y tiempos de inferencia evaluados permiten dar cumplimiento al OE4 (evaluar el desempeño mediante métricas estándar).

Por último, la etapa de desarrollo implementó una aplicación web interactiva y un pipeline automatizado que permiten simular el flujo completo desde la carga de una mamografía DICOM hasta la predicción de densidad mamaria. El sistema incorpora validaciones automáticas de formato (proyección CC, ausencia de implantes), preprocesamiento mediante segmentación y extracción radiómica, y predicción dual (binaria y multiclase) con niveles de confianza. Además, el 100% de las 30 imágenes utilizadas como conjunto de validación fueron procesadas correctamente por el sistema, superando todos los casos definidos en el plan de pruebas, cumpliendo así el OE5 (desarrollar e implementar una interfaz web funcional).

Todas las fases del proyecto, desde la definición de métricas hasta la interpretación de resultados y el diseño de la solución web, fueron revisadas y validadas conjuntamente con el asesor técnico, lo que respalda la pertinencia de las decisiones tomadas y la viabilidad de la propuesta en el contexto clínico real de la institución. De este modo, el proyecto evidencia que es factible automatizar la clasificación de densidad mamaria con métricas competitivas, tiempos de respuesta adecuados para su uso en entornos clínicos y una plataforma web funcional capaz de integrar todo el flujo de procesamiento, logrando cumplir tanto los objetivos específicos como el objetivo general planteado.

6. CONCLUSIONES Y FUTURO TRABAJO.

Este proyecto desarrolló un sistema de inteligencia artificial para la clasificación automatizada de la densidad mamaria en colaboración con la Fundación Valle del Lili (FVL), diseñado para asistir en la interpretación de mamografías dentro del entorno clínico. Esta clasificación resulta fundamental, dado que el tejido denso puede ocultar tumores en las imágenes y obstaculizar la detección temprana, además de representar en sí mismo un factor de riesgo para el desarrollo de cáncer de mama. El trabajo comprendió desde la preparación de mamografías en formato DICOM, la extracción y procesamiento de características radiómicas, hasta el diseño y entrenamiento de modelos de clasificación binaria y multiclase según BI-RADS, su evaluación mediante métricas de desempeño, y su integración en una aplicación web que incorpora desde la carga de mamografías hasta la predicción automática. A continuación, se presentan los principales logros y hallazgos obtenidos.

En primer lugar, la preparación y transformación de los datos consolidó un flujo estandarizado que integra la segmentación de imágenes con la extracción, estandarización y selección de características radiómicas, logrando reducir de 97 a 39 los predictores de los modelos, disminuyendo la complejidad computacional y manteniendo métricas consistentes en los modelos. Dicho comportamiento confirmó el cumplimiento de los objetivos OE1 y OE2.

En segundo término, la fase de modelado demostró la variedad de algoritmos para abordar el problema y la eficacia de estos. Tras optimizar cinco candidatos mediante búsqueda en malla, AdaBoost alcanzó un *F1-score* de 87.89% en el conjunto binario ciego derivado del CSV. Por su parte, XGBoost obtuvo un *F1-score* del 71.90% en el conjunto multiclase ciego. Estos resultados verifican el OE3 y respaldan el OE4, puesto que los modelos binarios superaron el umbral del 85% establecido por la FVL.

A su vez, en las pruebas con mamografías DICOM ajenas a los datos de entrenamientos, el modelo binario mantuvo un 80% de *Accuracy* tanto en la FVL como en el dataset público de la RSNA, mientras que el multiclase conservó el 80% sobre el primer conjunto, pero descendió al 35% en la RSNA, revelando la sensibilidad del modelo multiclase frente a variaciones en los equipos usados para obtener las imágenes.

En comparación con la publicación principal de referencia para este proyecto, el modelo binario SVM desarrollado en la Universidad Autónoma de Occidente (UAO), nuestro modelo binario AdaBoost obtuvo una mejora del 3.24% en *Accuracy* y del 1.99% en *F1-score*. Es importante destacar que esta comparación

se restringió al escenario binario, dado que el proyecto realizado en la UAO no incluyó un modelo multiclase. La mejora moderada se explica porque ambos trabajos emplearon el mismo conjunto de datos, compartiendo así sus características y sesgos inherentes.

Finalmente, la integración tecnológica permitió consolidar una aplicación web en Vue.js y Flask que reproduce el recorrido completo desde la carga de un archivo DICOM hasta la predicción final, incorporando validaciones de proyección, control de implantes, segmentación automática, extracción radiómica y generación de predicciones con niveles de confianza. El sistema procesó correctamente las 30 imágenes empleadas en la validación del flujo, demostrando estabilidad operativa del sistema y así el cumpliendo con el OE5. Con ello, el proyecto cierra el ciclo completo: desde la preparación de los datos, la construcción y evaluación de modelos, hasta su implementación funcional.

En síntesis, este proyecto demuestra que la automatización de la clasificación de densidad mamaria mediante IA es viable y funcional en el contexto clínico de la FVL, logrando un desempeño satisfactorio en clasificación binaria (*F1-score* de 87.89% y *Accuracy* de 89.04%), buenos tiempos de respuesta promedio (0.13 segundos por mamografía) y un *pipeline* reproducible. La contribución fundamental de este trabajo radica en un pipeline completo, documentado y operativo, que abre el camino para que esta tecnología sea evaluada en entornos hospitalarios reales y adoptada como herramienta de apoyo diagnóstico.

Como trabajo futuro, se propone incrementar la representación de las clases minoritarias (A y D), trabajar directamente con archivos DICOM originales para un control completo del preprocesamiento, optimizar el desempeño de SAM en proyecciones MLO y evaluar técnicas alternativas de selección de características. Desde la perspectiva clínica, se sugiere avanzar hacia la integración con los sistemas PACS de la FVL mediante un despliegue piloto en su infraestructura *on-premise*. Esta adopción consolidaría la contribución práctica del proyecto y abriría la puerta a extender la plataforma a otras modalidades diagnósticas dentro y fuera de la institución.

7. ANEXOS

7.1. Glosario de términos

BI-RADS:

Es un sistema estandarizado que clasifica la densidad mamaria y los hallazgos en mamografías para unificar la interpretación y los reportes radiológicos.

Densidad mamaria:

Cantidad de tejido fibroso y glandular en las mamas en comparación con el tejido graso.

DICOM:

Es un estándar internacional para el almacenamiento y transmisión de imágenes médicas que incluye metadatos clínicos.

F1-score:

Es una medida armónica entre *Precision* y *Recall* con el propósito de balancear la proporción de aciertos entre las clases positivas y negativas.

Flask:

Framework de Python para desarrollo de aplicaciones web y APIs.

HL7:

Es un conjunto de estándares para facilitar el intercambio electrónico de información clínica.

Información mutua:

Es una medida estadística que cuantifica la dependencia entre dos variables, útil para seleccionar características relevantes.

Machine Learning:

Rama de la inteligencia artificial que permite a las máquinas aprender patrones de datos sin programación explícita.

Mamografía:

Radiografía de la mama utilizada para detectar cáncer de mama y evaluar la densidad del tejido mamario.

Matriz de confusión:

Tabla que muestra las predicciones correctas e incorrectas de un modelo clasificador, desglosadas por cada clase.

Multicolinealidad:

Situación en la que dos o más variables predictoras están fuertemente correlacionadas entre sí, dificultando estimar de forma estable su efecto individual en un modelo.

Odds ratio:

Es una medida que cuantifica cuánto cambian las probabilidades relativas de que ocurra un evento cuando una variable explicativa varía en una unidad.

Parénquima:

Tejido funcional específico de un órgano que realiza su función principal.

Pipeline:

Secuencia automatizada de pasos de procesamiento de datos que garantiza reproducibilidad y consistencia.

Precision:

Indica qué proporción de predicciones positivas fueron correctas.

Recall:

Indica la proporción de positivos reales que fueron correctamente identificados.

Vue.js:

Framework de JavaScript para construir interfaces de usuario interactivas.

Wavelet:

Es una función matemática que descompone una señal o imagen en componentes de distintas escalas para analizar sus detalles.

7.2. Lista de acrónimos

AI	Inteligencia Artificial (<i>Artificial Intelligence</i>)
API	Interfaz de Programación de Aplicaciones (<i>Application Programming Interface</i>)
BI-RADS	Sistema de datos e informes de imágenes mamarias (<i>Breast Imaging-Reporting and Data System</i>)
CC	Cráneo Caudal
cGAN	Redes Generativas Antagónicas Condicionales (<i>Conditional Generative Adversarial Networks</i>)
CNN	Red Neuronal Convolucional (<i>Convolutional Neural Network</i>)
CRISP-DM	Metodología Estándar del Proceso de Minería de Datos (<i>Cross-Industry Standard Process for Data Mining</i>)
CSV	Valores Separados por Comas (<i>Comma Separated Values</i>)
DICOM	<i>Digital Imaging and Communications in Medicine</i>
FVL	Fundación Valle del Lili
HL7	Nivel de Salud Siete (<i>Health Level Seven</i>)
KNN	K Vecinos Más Cercanos (<i>K-Nearest Neighbors</i>)
MLO	Medio Lateral Oblicua
OE	Objetivo específico
PACS	Sistema de Archivo y Comunicación de Imágenes (<i>Picture Archiving and Communication System</i>)
RSNA	Sociedad Radiológica de Norteamérica (<i>Radiological Society of North America</i>)
SMOTE	Técnica de Sobremuestreo de Minorías Sintéticas (<i>Synthetic Minority Over-sampling Technique</i>)
SVM	Máquina de Vectores de Soporte (<i>Support Vector Machine</i>)
UAO	Universidad Autónoma de Occidente

VIF Factor de Inflación de la Varianza (*Variance Inflation Factor*)

8. REFERENCIAS BIBLIOGRÁFICAS

Angulo, E. M. (2019, 15 septiembre). Errores médicos, las sentencias de muerte de 2,6 millones de pacientes por año. France 24. <https://www.france24.com/es/20190914-errores-medicos-oms-muerte-salud>

Arturo Angulo, D. A., Petrel García, G., Moreno Pineda, S., Puerta Gaviria, L. C., Solís Ríos, D., Orejuela, J. F., Ortigoza Micolta, D., Pulgarín Giraldo, J. D., & González Vargas, A. M. (2020). Sistema de clasificación de tipo de tejido mamario con machine learning. INICIACIÓN CIENTÍFICA, 9, 29–41. <https://iniciacioncientifica.com/editorial/index.php/libros/article/view/39/36>.

Boyd, N. F., Guo, H., Martin, L. J., Sun, L., Stone, J., Fishell, E., Jong, R. A., Hislop, G., Chiarelli, A., Minkin, S., & Yaffe, M. J. (2007). Mammographic Density and the Risk and Detection of Breast Cancer. New England Journal Of Medicine, 356(3), 227-236. <https://doi.org/10.1056/nejmoa062790>

Breast Cancer Research Foundation. (2025). *Dense Breast Tissue: Risks, Detection, & Screening Options*. Retrieved from <https://www.bcrf.org/about-breast-cancer/dense-breast-tissue/>

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS. <https://www.kde.cs.uni-kassel.de/wp-content/uploads/lehre/ws2012-13/kdd/files/CRISPWP-0800.pdf>

Deng, J., Ma, Y., Li, D., Zhao, J., Liu, Y., & Zhang, H. (2020). Classification of breast density categories based on SE-Attention neural networks. Computer Methods and Programs in Biomedicine, 193, 105489. <https://pubmed.ncbi.nlm.nih.gov/32434061/>

Diccionario de cáncer del NCI. (s. f.). Cancer.gov. <https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/radiografia>

Du Cancer, C. C. S. / S. C. (2024, 1 enero). Breast density. Canadian Cancer Society. <https://cancer.ca/en/treatments/tests-and-procedures/mammography/breast-density#:~:text=BI%2DRADS%20A%3A%20The%20breast,breast%20is%20mostly%20dense%20tissue>

Fundación Valle de Lili. (2023, 18 agosto). Nuestra institución - Fundación Valle del Lili. Fundación Valle del Lili. <https://valledellili.org/nuestra-institucion/>

Fundación Valle de Lili. (2024, 1 marzo). Imágenes diagnósticas - Fundación Valle del Lili - Cali - Colombia. Fundación Valle del Lili. <https://valledellili.org/departamentos-y-servicios/imagenes-diagnosticas/#:~:text=El%20Servicio%20se%20caracteriza%20por,estudios%20de%20las%20diferentes%20subespecialidades>

Ibm. (2024a, abril 22). Segmentación de imágenes. IBM. <https://www.ibm.com/es-es/topics/image-segmentation>

Ibm. (2024b, julio 12). MLOps. IBM. <https://www.ibm.com/es-es/topics/mlops/#:~:text=MLOps%2C%20abreviatura%20de%20operaciones%20de,ejecutar%20modelos%20de%20machine%20learning>

Loizidou, K., Elia, R., & Pitris, C. (2023). Computer-aided breast cancer detection and classification in mammography: A comprehensive review. Computers in Biology and Medicine, 153, 106554. <https://doi.org/10.1016/j.compbimed.2023.106554>

Machine learning: Definición, Ventajas y Desventajas. (s. f.). Salesforce. <https://www.salesforce.com/es/resources/definition/machine-learning/#topic1>

Mamografías. (s. f.). Cancer.gov. <https://www.cancer.gov/espanol/tipos/seno/hoja-informativa-mamografias#que-es-una-mamografia>

Mayerhoefer, M. E., Materka, A., Langs, G., Häggström, I., Szczypiński, P., Gibbs, P., & Cook, G. (2020). Introduction to Radiomics. Journal Of Nuclear Medicine, 61(4), 488-495. <https://doi.org/10.2967/jnumed.118.222893>

Radiomic Features — pyradiomics v3.1.0rc2.post5+g6a761c4 documentation. (s. f.). <https://pyradiomics.readthedocs.io/en/latest/features.html#module-radiomics.glcm>

Radiómica | #AnticipandoelFuturo. (s. f.). <https://www.institutooroche.es/observatorio/radiomica>

Saffari, N., Rashwan, H. A., Abdel-Nasser, M., Singh, V. K., Arenas, M., Mangina, E., Herrera, B., & Puig, D. (2020). Fully Automated Breast Density Segmentation and Classification Using Deep Learning. Diagnostics, 10(11), 988. <https://pmc.ncbi.nlm.nih.gov/articles/PMC7700286/pdf/diagnostics-10-00988.pdf>

- Shrinithi, S., Vijayan, D., & Lavanya, R. (2022). Computer aided diagnosis system for breast density classification in mammograms. *Journal of Physics: Conference Series*, 2318(1), 012039. <https://iopscience.iop.org/article/10.1088/1742-6596/2318/1/012039/pdf>
- Spak, D. A., Plaxco, J. S., Santiago, L., Dryden, M. J., & Dogan, B. E. (2017). BI-RADS fifth edition: A summary of changes. *Diagnostic and Interventional Imaging*, 98(3), 179–190. <https://www.sciencedirect.com/science/article/pii/S2211568417300013>
- Stryker, C., & Kavlakoglu, E. (2025, 23 abril). Inteligencia artificial. IBM. <https://www.ibm.com/mx-es/topics/artificial-intelligence>
- Wang, E. Y., Wang, V. Y., Chen, X., Feng, B., Chen, C., Yan, R., Zhu, L., & Xu, D. (2025). Deep learning prediction of mammographic breast density using screening data. *Scientific Reports*, 15(1), 11602. <https://www.nature.com/articles/s41598-025-95275-5>